

UCTransNet: Rethinking the Skip Connections in U-Net from a Channel-Wise Perspective with Transformer

Haonan Wang^{1,2}, Peng Cao^{1,2*}, Jiaqi Wang^{1,2}, Osmar R. Zaiane³

AAAI-22

摘要

最新的语义分割方法采用了具有编码器-解码器架构的 U-Net 框架。然而，对于采用简单跳跃连接方案的 U-Net 来说，要模拟全局多尺度上下文仍然具有挑战性：1) 并非每种跳跃连接设置都有效，因为编码器和解码器阶段的特征集不兼容，甚至有些跳跃连接会负面影响分割性能；2) 在某些数据集上，原始的 U-Net 比没有任何跳跃连接的情况表现更差。基于我们的发现，我们提出了一种新的分割框架，命名为 UC-TransNet（在 U-Net 中加入了一个名为 CTrans 的模块），它从通道角度并结合注意力机制进行设计。具体来说，CTrans（通道变换器）模块是 U-Net 跳跃连接的一个替代方案，它包括一个子模块用于进行多尺度通道交叉融合，采用变换器（命名为 CCT）和一个通道方向的交叉注意力子模块（命名为 CCA），以指导融合后的多尺度通道信息有效连接到解码器特征，消除歧义。因此，由 CCT 和 CCA 组成的提出的连接能够替换原始跳跃连接，解决语义间隙，实现准确的自动医学图像分割。实验结果表明，UCTransNet 产生了更精确的分割性能，并在不同数据集及涉及变换器或 U 型框架的传统架构上，实现了一致的性能提升。而我在 UCTransNet 的基础上引入了 U2-Net 的思想，并在每次下采样时分为两路，分别进行卷积和空洞卷积，再把产生的特征图进行拼接后进行跳跃连接的选择，得到了较为不错的分割效果。

关键词：U-Net；图像分割

1 引言

医学成像被视为协助医生评估疾病并优化预防和控制措施的重要技术。医学图像中目标对象的分割及其后量化评估为病理分析提供宝贵信息，并对治疗策略的规划、疾病进展的监测和患者预后的预测具有重要意义。近期的方法（Long、Shelhamer 和 Darrell 2015 年；Ni 等人 2020 年；Wen、Xie 和 He 2020 年）通常依赖于卷积编码器-解码器架构，其中编码器生成低分辨率图像特征，解码器将特征上采样为具有每像素类别得分的分割图。U-Net [2]（Ronneberger、Fischer 和 Brox 2015 年）是医学图像分割中最广泛使用的编码器-解码器网络架构，因为编码器捕获低级和高级特征，解码器结合语义特征构建最终结果。跳跃连接有助于传播在池化操

作中丢失的空间信息，通过编码-解码过程恢复完整的空间分辨率。为了研究这一点，本文作者对 U-Net 进行了深入研究，并根据对多个数据集的分析，发现了几个主要限制。本文作者发现，对于采用简单跳跃连接方案的 U-Net 来说，在辅助解码过程中模拟全局多尺度上下文而不考虑语义差距仍然具有挑战性。因此，有必要找到一种有效的融合特征的方法以实现精确的医学图像分割。U-Net 的扩展本质上存在两个关键问题：哪些编码器层的特征与解码器连接以通过聚合多尺度特征来模拟全局上下文，以及如何有效融合可能存在语义差距的特征而不是简单地连接？存在两个语义差距：多尺度编码器特征之间的语义差距以及编码器和解码器阶段之间的语义差距，限制了分割性能。为了克服这一限制，最近引入了许多方法来缓解这两组不兼容特征融合时的差异。一种方法是用嵌套密集跳跃路径直接替换简单的跳跃连接，用于医学图像分割。最具代表性的方法是 UNet++ (Zhou 等人 2018 年)，它通过引入密集连接和一系列卷积，缩小了编码器和解码器子网络之间的语义差距，并实现了更好的分割性能。这是对 U-Net 中只要求融合相同尺度特征图的限制性跳跃连接的改进。另一种方法侧重于通过在编码器阶段的特征上引入额外的非线性变换来加强跳跃连接，应对或在某种程度上平衡可能的语义差距 (Rahman 2020 年)。

尽管取得了良好的性能，但上述工作仍无法有效地从全尺度中探索足够信息。捕获多尺度特征对于解决医学图像分割中的复杂尺度变化至关重要。由于这些重要问题，一个问题出现了：如何通过多尺度通道信息融合有效捕获非本地语义依赖性，充分弥合编码器和解码器之间的语义差距。本文作者重新思考了跳跃连接的设计，并提出了一种更好连接编码器和解码器阶段特征的替代方法。不同的通道通常专注于不同的语义模式，适应性地融合足够的通道特征有利于复杂的医学图像分割。为此，本文作者提出了一种名为 UCTransNet 的端到端深度学习网络，以 U-Net 为网络的主要结构。更具体地说，本文首先提出了一个通道交叉融合变换器 (CCT)，从通道角度融合多尺度上下文和交叉注意力。其目的是捕获局部跨通道交互，实现一种自适应方案，以协作学习而非独立连接的方式有效融合可能存在尺度语义差距的多尺度通道特征。另一方面，本文作者提出了另一个通道交叉注意力 (CCA) 模块，用于融合融合的多尺度特征和解码器阶段的特征，解决不一致的语义级别。这两个交叉注意模块统称为 CTrans (通道变换器)，可以通过探索多尺度全局上下文建立编码器和解码器之间的关联，并替换原始跳跃连接以解决语义差距，从而提高分割性能。这两个提出的模块可以轻松嵌入并应用于医学图像分割任务中的 U 型网络。广泛的实验表明，UCTransNet 可以通过以下绝对增益大幅提高传统分割流程的性能：在 GlaS、MoNuSeg 和 Synapse 数据集上分别比 U-Net 高出 4.05%、7.98% 和 9.00% 的 Dice 系数。此外，本文作者进行了深入分析，以探究特征交互是如何工作的。此外，之前的研究将 Transformers 和 U-Net 结合起来，以显式建模长距离空间依赖性 (Chen 等人 2021 年；Zhang、Liu 和 Hu 2021 年)。结果表明，通道融合变换器方案通常比将变换器替代卷积操作的方法性能更好。本文作者认为，UCTransNet 可以作为医学图像分割的强大跳跃连接方案。

本文作者的贡献有三个方面。1) 本研究是首个在多个数据集上充分探索 U-Net 跳跃连接潜在弱点并发现独立简单复制不适当的工作。2) 本文作者提出了一种提升语义分割性能的新视角，即通过更有效的多尺度通道交叉注意力特征融合来弥合低级和高级特征之间的语义和分辨率差距，以捕获更复杂的通道依赖性。3) 本文作者的方法是 U-Net 和 Transformer 的更合适组合，计算成本更低，性能更高。与其他最先进的分割方法相比，实验结果在所有三个公共数据集上都表现出更好的性能。

2 相关工作

最近,视觉变换器 (Vision Transformer, ViT) (Dosovitskiy 等人 2020 年) 通过直接将具有全局自注意力的变换器应用于全尺寸图像,在 ImageNet 分类中取得了最先进的成果。由于变换器在许多计算机视觉领域的成功,近期医学图像分割的新范式已逐渐发展 (Zheng 等人 2020 年; Zhang 等人 2021 年; Gao 等人 2021 年; Ji 等人 2021 年; Gao、Zhou 和 Metaxas 2021 年; Zhang、Liu 和 Hu 2021 年; Hatamizadeh 等人 2021 年)。TransUNet (Chen 等人 2021 年) 是第一个基于变换器的医学图像分割框架。Valanarasu 等人提出了一个门控轴向注意模型——MedT (Valanarasu 等人 2021 年),以克服医学成像中数据样本数量少的问题。由 Swin Transformer (Liu 等人 2021 年) 所激发,该变换器取得了最先进的性能, Swin-Unet (Cao 等人 2021 年) 提出了第一个纯变换器基础的 U 形架构,引入 Swin Transformer 替换了 U-Net 中的卷积块。然而,上述方法主要关注卷积操作的缺陷,而非 U-Net 本身,因此可能导致结构冗余和过高的计算成本。

2.1 U 形网络中的跳跃连接

跳跃连接机制最初在 U-Net 中被提出 (Ronneberger、Fischer 和 Brox 2015 年),旨在弥合编码器和解码器之间的语义差距,并已证明在恢复目标对象的细粒度细节方面有效 (Drozdal 等人 2016 年; He 等人 2016 年; Huang 等人 2017 年)。随着 U-Net 的普及,许多新颖的模型被提出,如 UNet++ [3] (Zhou 等人 2018 年)、Attention U-Net (Oktay 等人 2018 年)、DenseUNet (Li 等人 2018 年)、R2U-Net (Alom 等人 2018 年) 和 UNet 3+ (Huang 等人 2020 年),这些模型专为医学图像分割设计,取得了显著性能 (见图 1)。Zhou 等人 (2018 年) 认为来自编码器和解码器网络的同尺度特征图在语义上不同,因此设计了一个名为 UNet++ 的嵌套结构,它捕获多尺度特征以进一步弥合差距。Attention-UNet 提出了交叉注意模块,使用粗尺度特征作为门控信号来消除跳跃连接中的不相关和噪声响应。MultiResUNet (Rahman 2020 年) 观察到可能存在跳过的编码器特征和解码器特征之间的语义差距,因此引入了具有残差结构的 Res Path 以改进跳跃连接 (见图 1)。这些方法假设每个跳跃连接的贡献相等,然而这些连接的贡献是不同的,有些甚至可能损害最终性能。

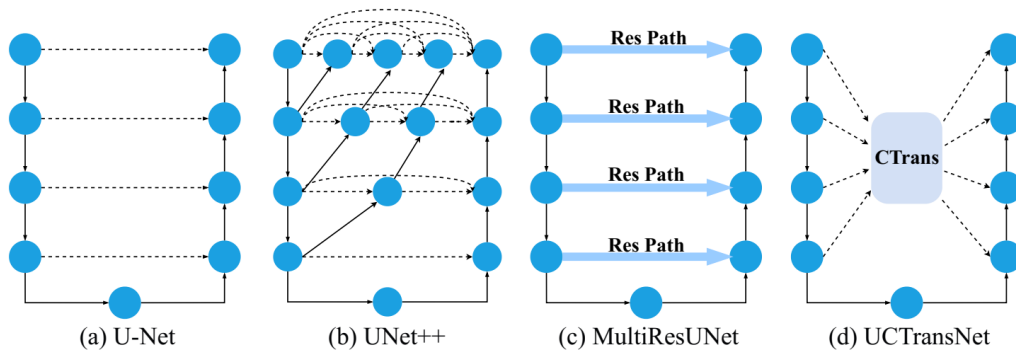


图 1. U-Net 模型结构图

2.2 跳跃连接的分析

在本节中，本文对三个数据集上跳跃连接对分割性能的贡献进行了全面分析。根据分析，以下三个发现突出显示：

发现 1：没有任何跳跃连接的 U-Net 甚至比原始 U-Net 表现更好。比较图 2 的结果，可以发现在 MoNuSeg 数据集上几乎所有指标中，“U-Net-none”展示了最差的性能。然而，“U-Net-none”尽管没有任何约束，仍然在 GlaS 数据集上与“U-Net-all”展现出非常有竞争力的性能。这表明跳跃连接并不总是对分割有益。

发现 2：虽然 UNet-all 的表现优于 UNet-none，但并非所有简单复制的跳跃连接对分割都有用。每个跳跃连接的贡献不同。我们发现在 MoNuSeg 数据集上，每个跳跃连接的性能范围分别为 [67.5%,76.44%] 和 [52.2%,62.73%]，分别对应 Dice 和 IOU。不同单个跳跃连接的影响变化大。此外，由于编码器和解码器阶段特征集不兼容的问题，某些跳跃连接负面影响分割性能。例如，在 GlaS 数据集上，L1 在 Dice 和 IOU 方面的表现比 UNet-none 更差。结果并不表明编码器阶段的许多特征不具信息性。其背后的原因可能是简单复制不适用于特征融合。

发现 3：不同数据集的最佳跳跃连接组合不同，这取决于目标病变的尺度和外观。本文进行了几个消融实验以探索最佳的边输出设置。需要注意的是，由于空间有限，本文忽略了两个跳跃连接的组合。但是忽略后可以看出，跳跃连接并没有达到更好的性能。在 MoNuSeg 数据集上，没有 L4 的模型表现最好，而令人惊讶的是，在 GlaS 数据集上，仅具有一个跳跃连接的 L3 表现最好。这些观察结果表明，最佳组合因不同数据集而异，进一步证实了引入更合适的特征融合方式，而非简单连接的必要性。

2.3 对于 U2-Net 的集成

与此同时，U2-Net [1]（Qin 等人 2020 年）提出了一种新型网络，特别适用于处理复杂图像分割任务。U2-Net 采用了一种独特的 U-型网络架构，其中包含多个嵌套的 U-型结构，这些结构被设计用于精确捕获图像的不同尺度特征。本文作者认为，U2-Net 在处理具有复杂纹理和结构的医学图像时显示出了显著的优势，特别是在细节丰富或需要高度精确分割的情况下。




图 2. 去除不同跳跃连接的结果

3 本文方法

3.1 UCTransNet 用于医学图像分割

UCTransNet 框架的概览如图 3 所示。当前基于变换器的分割方法主要集中于改进 U-Net 的编码器, 利用其捕获长距离信息的优势。例如, TransUNet (Chen 等人 2021 年) 和 TransFuse (Zhang、Liu 和 Hu 2021 年) 等方法通过简单的方式将变换器与 U-Net 结合, 将变换器模块插入编码器中或融合两个独立分支。然而, 分析表明, U-Net 模型的一个潜在限制是跳跃连接的问题, 而非原始 U-Net 的编码器。在跳跃连接分析部分中指出, 编码器的特征与解码器的特征可能不一致, 特别是在较浅层次的特征中, 较少的语义信息可能会通过简单的跳跃连接造成最终性能的损害, 这是由于编码器和解码器之间的语义差距。因此, 设计了一个在原始 U-Net 编码器和解码器之间的通道级变换器模块, 称为 UCTransNet 框架, 以更好地融合编码器特征并减少语义差距。具体而言, 引入了一个通道变换器 (CTrans), 用于替换 U-Net 中的跳跃连接, 包括两个模块: CCT (通道交叉融合变换器) 用于多尺度编码器特征融合, 以及 CCA (通道交叉注意力) 用于融合解码器特征和增强的 CCT 特征。

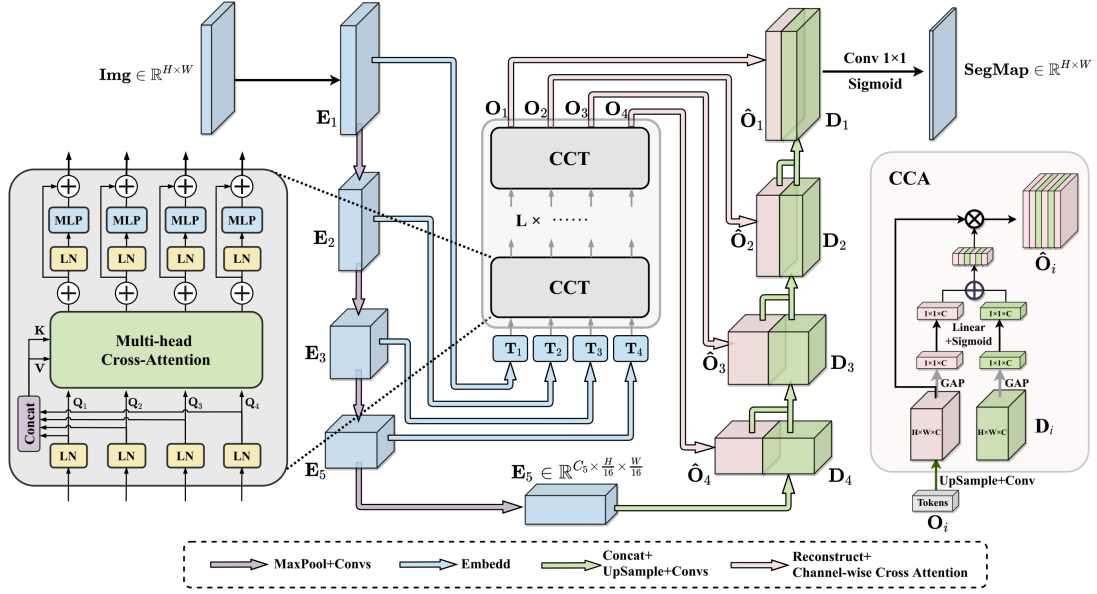


图 3. UCTransNet 模型结构图

3.2 CCT: 用于编码器特征转换的通道交叉融合变换器

为了解决前文提到的跳跃连接问题，本文提出了一种新的通道交叉融合变换器（CCT），用于融合多尺度编码器特征，并利用变换器在长期依赖性建模方面的优势。CCT 模块包括三个步骤：多尺度特征嵌入、多头通道交叉注意力和多层感知机（MLP）。

3.3 多尺度特征嵌入

给定四个跳跃连接层的输出 $E_i \in \mathbb{R}^{H_i W_i \times C_i}$, $i = 1, 2, 3, 4$ ，首先通过跨注意力（CA）机制执行标记化，将特征重塑成平坦化的 2D 块序列，块大小为 M_i ：

$$CA_i = M_i V^\top = \sigma(Q_{p_i}^\top C K \Sigma) V^\top = \sigma(W_i^Q T_{p_i}^\top C T \Sigma \Sigma W^K) W^V T^\top \Sigma$$

其中 $\sigma(\cdot)$ 表示 softmax 函数， (\cdot) 表示实例归一化（Ulyanov, Vedaldi, 和 Lempitsky 2017）。与原始自注意力不同，我们沿着通道轴而不是块轴进行注意力操作（见图 4），并采用实例归一化，这可以归一化相似度矩阵上每个实例的相似度映射，使梯度能够顺利传播。




图 4. 通道注意力对比图

3.4 CCA: 解码器中的通道交叉注意力特征融合

为了更好地融合通道变换器和 U-Net 解码器之间语义不一致的特征，我们提出了一个通道交叉注意力模块，可以指导变换器特征的通道和信息过滤，并消除与解码器特征的歧义。在数学上，我们将第 i 级变换器输出 $O_i \in \mathbb{R}^{C \times H \times W}$ 和第 i 级解码器特征图 $D_i \in \mathbb{R}^{C \times H \times W}$ 作为通道交叉注意力的输入。通过全局平均池化 (GAP) 层进行空间压缩，生成向量 $G(X) \in \mathbb{R}^{C \times 1 \times 1}$ ，其第 k 个通道 $G(X) = \frac{1}{HW} \sum_{i=1}^H \sum_{j=1}^W X_k(i, j)$ 。我们使用此操作来嵌入全局空间信息，然后生成注意力掩码：

$$M_i = L_1 \cdot G(O_i) + L_2 \cdot G(D_i)$$

其中 $L_1 \in \mathbb{R}^{C \times C}$ 和 $L_2 \in \mathbb{R}^{C \times C}$ 是两个线性层的权重，ReLU 操作符 $\delta(\cdot)$ 。等式 (5) 中的操作编码了通道间的依赖性。

3.5 CCA: 解码器中的通道交叉注意力特征融合

令牌然后被送入多头通道交叉注意力模块，随后是具有残差结构的多层感知机 (MLP)，以利用多尺度特征对每个 U-Net 编码器级别的特征进行细化和编码通道和依赖关系。

如图 5 所示，提出的 CCT 模块包含五个输入，包括四个令牌 T_i 作为查询，以及一个连接令牌 T_Σ 作为键和值：

$$Q_i = T_i W_i^Q; K = T_\Sigma W^K; V = T_\Sigma W^V$$

其中 $W_i^Q \in \mathbb{R}^{C_i \times d}$, $W^K \in \mathbb{R}^{C_\Sigma \times d}$, $W^V \in \mathbb{R}^{C_\Sigma \times d}$ 是不同输入的权重, d 是序列长度 (块数), $C_i (i = 1, 2, 3, 4)$ 是四个跳跃连接层的通道维数。在我们的实现中 $C_1 = 64, C_2 = 128, C_3 = 256, C_4 = 512$ 。




图 5. 多头注意力机制示意图

4 复现细节

4.1 与已有开源代码对比

在本文的复现过程中, 我将源代码中的模型结构部分做了改变。首先是引入了一个与原来不同的下采样过程:

```
showstringspaces
class ModifiedDownBlock(nn.Module):
    """Downscaling with maxpool convolution and dilated convolution"""
    def __init__(self, in_channels, out_channels, nb_Conv, activation='ReLU'):
        super(ModifiedDownBlock, self).__init__()
        self.maxpool = nn.MaxPool2d(2)
        self.nConvs_standard = _make_nConv(in_channels, out_channels, nb_Conv,
                                             activation)
        self.nConvs_dilated = _make_nConv(in_channels, out_channels, nb_Conv,
                                             activation)

        % Replace standard convolutions with dilated convolutions in
        nConvs_dilated
```



```

for i in range(nb_Conv):
    self.nConvs_dilated[i] = DilatedConvBatchNorm(out_channels,
                                                    out_channels, activation)

def forward(self, x):
    x = self.maxpool(x)
    conv_standard = self.nConvs_standard(x)
    conv_dilated = self.nConvs_dilated(x)
    return torch.cat([conv_standard, conv_dilated], dim=1) % Concatenate
                        along the channel dimension

```

通过 ModifiedDownBlock 函数，实现了使用两种卷积方式同时得到特征图并合并的过程。

然后我又引入了 U2-Net 的相关模式，即在每一层模拟一个小型的 U-Net，使之提取更多的特征图输入到后续的上采样过程中，从而让模型能够学习到更多维度的特征。

showstringspaces

```

class U2DownBlock(nn.Module):
def __init__(self, in_channels, out_channels):
    super(U2DownBlock, self).__init__()
    self.conv1 = nn.Conv2d(in_channels, out_channels, kernel_size=3, padding
                             =1)
    self.bn1 = nn.BatchNorm2d(out_channels)
    self.relu1 = nn.ReLU(inplace=True)

    self.conv2 = nn.Conv2d(out_channels, out_channels, kernel_size=3,
                             padding=1)
    self.bn2 = nn.BatchNorm2d(out_channels)
    self.relu2 = nn.ReLU(inplace=True)

    self.maxpool = nn.MaxPool2d(2)

def forward(self, x):
    x = self.relu1(self.bn1(self.conv1(x)))
    x = self.relu2(self.bn2(self.conv2(x)))
    x_pooled = self.maxpool(x)
    return x, x_pooled

class U2UpBlock(nn.Module):
def __init__(self, in_channels, out_channels):
    super(U2UpBlock, self).__init__()
    self.up = nn.ConvTranspose2d(in_channels, out_channels, kernel_size=2,
                                  stride=2)
    self.conv1 = nn.Conv2d(in_channels, out_channels, kernel_size=3, padding
                             =1)
    self.bn1 = nn.BatchNorm2d(out_channels)
    self.relu1 = nn.ReLU(inplace=True)

    self.conv2 = nn.Conv2d(out_channels, out_channels, kernel_size=3,
                             padding=1)

```

```

        self.bn2 = nn.BatchNorm2d(out_channels)
        self.relu2 = nn.ReLU(inplace=True)

    def forward(self, x, skip_input):
        x = self.up(x)
        x = torch.cat([x, skip_input], dim=1)  # Concatenate along channel
        dimension
        x = self.relu1(self.bn1(self.conv1(x)))
        x = self.relu2(self.bn2(self.conv2(x)))
        return x

```

通过 U2DownBlock 和 U2UpBlock，成功引入了 U2-Net 的思想。以上就是我对复现源代码的改动，一些细节的改动就不予列出了。

4.2 实验环境搭建

本复现过程使用 python3.8 环境，PyTorch 版本为 1.11.1，cuda 版本为 11.6。在实验开始前，先创建一个新的 conda 环境，然后导入 requirement.txt 将所需的第三方库下载完成，即可正常运行。

4.3 实验数据集

本次复现我使用的是 MoNuSeg 数据集。MoNuSeg 数据集是一个专门为推进医学图像分析领域而创建的数据集，特别关注于病理学图像中的细胞核分割。以下是这个数据集的主要特点。

图像来源：MoNuSeg 数据集中的图像来源于 H&E（苏木精-伊红）染色组织图像。这些图像以 40 倍的高倍率拍摄，并从 TCGA（癌症基因组图谱）档案中下载。

用途与应用：H&E 染色是医学病理学中的标准程序，主要用于提高组织切片的对比度。它在肿瘤评估（分级、分期等）中发挥着重要作用。这些图像中细胞核的多样性，由于涉及多种器官和多家医院使用的染色协议，使得这个数据集成为开发鲁棒性和通用性细胞核分割技术的宝贵资源。

训练和测试数据：MoNuSeg 数据集包括一个训练集，包含 30 张图像和约 22,000 个核边界的注释。测试集包括额外的图像，大约有 7,000 个核边界注释。这些图像涵盖了多种器官，由经验丰富的病理学家标注，为训练和评估提供了可靠的真实数据。

多样化的医疗应用：数据集广泛代表了不同器官和多家医院使用的染色协议，使其能够开发出适用于各种医学图像分析应用的多功能和适应性强的细胞核分割技术。

获取方式和许可：MoNuSeg 的挑战数据在创意共享许可下发布，便于研究和教育用途的使用。

技术细节：MoNuSeg 数据集中的每张图像都以高分辨率（通常为 1000x1000 像素）捕获。这种高分辨率成像对于详细分析和准确的病理学细胞核分割至关重要。

4.4 创新点

根据原文献的内容，作者提出了一种基于注意力机制的跳跃连接通道选择策略。这种策略可以学习每条跳跃连接对于结果的重要程度，决定它们参与最终特征图融合的权重。

因此，我认为可以在模型的下采样部分做一些变化，使模型能够提取到更多的特征图、产生更多的跳跃连接，从而提高模型的分割准确度。在此前我读过 U2-Net 的文献，这是一个在提取图像特征上有着非常好效果的模型。因此我加入了如 4.1 中的两个模块，即使用 U2-Net 的思想和两种卷积的叠加来实现这一想法。

5 实验结果分析

图 6 是复现原文模型和我的改进版本对分割结果的一个横向对比图。其中 gt 为真实标签，50 和 100 分别代表提前停止的迭代次数，即如果模型的最高精确度在 50 或 100 次迭代内不发生改变，就终止训练。从结果对比图中可以看出，100 次提前停止通常具有更好的效果，我的模型也比原文的模型得到的分割结果更加清晰、细致。




图 6. 实验结果对比

Method	MoNuSeg Dice%
文中	79.87
UCTransNet-50	78.31
UCTransNet-100	78.41
ours-50	79.75
ours-100	79.99

表 1. 不同方法在 MoNuSeg 数据集上的 Dice% 比较

6 总结与展望

在这篇文章中，作者首次提出了使用注意力机制来改善 U-Net 模型跳跃连接的策略。这一策略提供了一个思路，即通过引入更多的技巧来改善图像分割下采样模块和上采样模块之间的联系，而不是仅关注特征的提取和融合。这种策略可以被很容易地加入到当下成熟的图像分割模型中，取得一个很好的辅助效果，是一个比较创新性的工作。

在复现的过程中，我对于 U-Net 跳跃连接和 Transformer 注意力机制的理解加深了很多，并学习到了作者发现问题的过程。这使我获益颇多。

参考文献

- [1] Xuebin Qin, Zichen Zhang, Chenyang Huang, et al. U2-net: Going deeper with nested u-structure for salient object detection. *Pattern recognition*, 106:107404, 2020.
- [2] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5–9, 2015, Proceedings, Part III*, volume 18, pages 234–241. Springer International Publishing, 2015.
- [3] Zongwei Zhou, M M R Siddiquee, Nima Tajbakhsh, et al. Unet++: Redesigning skip connections to exploit multiscale features in image segmentation. *IEEE transactions on medical imaging*, 39(6):1856–1867, 2019.